



Facultad de Ingeniería
Tópicos Avanzados en Analítica

Proyecto 1 Detección de Frailejones

Proyecto 1 grupal

Detección de Frailejones con Redes Neuronales.

Luis Frontuso Garces , Miguel Humberto Zuñiga Paredes , Tannia Lucía Hernández Roja,,

Docente: Sergio Alberto Mora Pardo

BUSINESS UNDERSTANDING

Background: Este caso de estudio hace parte de un proyecto de Ingeniería que busca preservar y monitorizar el ecosistema del páramo, de gran importancia por su potencial hídrico, mediante la propuesta de una metodología para la reconstrucción del ecosistema en zonas de baja densidad de poblaciones de la especie *Espeletia*.

Business goal:

1. Aumentar el conocimiento de la distribución de "frailejones" mediante análisis de imágenes con diferentes modelos de redes neuronales.
2. Mejorar la conservación mediante un seguimiento efectivo de las poblaciones de "frailejones".
3. Facilitar la toma de decisiones para la restauración del ecosistema en zonas con baja densidad.

Business success criteria:

1. Incrementar la precisión del modelo en la detección de "frailejones".
 - **KPI:** Accuracy del modelo

Data mining goal:

1. Desarrollar un modelo eficiente y preciso de clasificación para detectar "frailejones" en imágenes usando técnicas de machine learning.
2. Identificar patrones en las características de las imágenes que llevan a resultados correctos en la clasificación.
3. Evaluar la efectividad del modelo en datos no vistos para asegurar que la generalización es adecuada.

Data mining success criteria:

1. **KPI:** Accuracy del modelo superior al 85% dependiendo del modelo.

DATA UNDERSTANDING

Describe data: El conjunto de datos utilizado está compuesto por imágenes de frailejones y de otros elementos del entorno. Su análisis permite comprender las características y posibles desafíos en el procesamiento de imágenes para la clasificación.

- Fuente: Las imágenes provienen de un dataset con ejemplos de frailejones y otros elementos del ecosistema.
- Cantidad de imágenes: 50 imágenes.
 - 21 imágenes corresponden a frailejones.
 - 29 imágenes corresponden a otros elementos del ecosistema.
- Dimensiones: Cada imagen tiene un tamaño original de 100x100 píxeles.
- Formato: Las imágenes son procesadas como arreglos numéricos (numpy arrays), convertidos a valores de punto flotante en el rango [0,1].

DATA PREPARATION

Durante esta etapa, los datos son preprocesados para asegurar un formato uniforme y facilitar su uso en los modelos de aprendizaje.

- Preprocesamiento de imágenes: Para garantizar que todas las imágenes de entrada tengan el mismo tamaño, se realiza un ajuste mediante redimensionamiento, asegurando que todas las imágenes procesadas sean de 70 x 70 píxeles.
- Normalización de datos: Las imágenes son convertidas a valores flotantes en el rango [0,1] para mejorar la estabilidad numérica de los modelos.
- Extracción de patches: Para cada imagen, se extraen regiones de interés en tamaños específicos. Lo que garantiza que las muestras extraídas tengan la dimensión correcta y sean homogéneas en el dataset.
- Data Augmentation: Se realizan rotaciones aleatorias para generar variaciones de perspectiva, escalado y recortes para simular diferentes distancias de captura, ajuste de brillo y contraste para manejar variaciones de iluminación, flipping horizontal y vertical para aumentar la diversidad del dataset y adición de ruido aleatorio, para robustecer el modelo contra imágenes con interferencias.

MODELING & EVALUATION

Select modeling techniques: Se implementaron cinco tipos de redes neuronales:

1. Red Neuronal Sencilla.
2. Red Neuronal Multicapa (MLP) con ajuste de hiperparámetros usando optuna..
3. Red Convolutiva (CNN) con ajuste de hiperparámetros usando optuna..
4. Red Convolutiva + VGG16.
5. Red Convolutiva + VGG16 con ajuste de hiperparámetros usando optuna.

RED NEURONAL SENCILLA

Generate test design:

Para evaluar los modelos propuestos, se ha diseñado un conjunto de pruebas basado en los siguientes mecanismos:

- División de los datos: se dividen los datos en dos train y validation que representan un 80%, y 20% del total de las observaciones.

- Mecanismos de control del sobreajuste/subajuste:
 - Se monitorea la pérdida y la precisión en entrenamiento y validación.
 - Se utilizan callbacks para guardar pesos del modelo en cada época.
 - Se usa validación cruzada para detectar sobreajuste.
- Método de comparación de los modelos: Se evalúa el accuracy, precision, y recall en el dataset de validación y de esta manera el modelo más preciso será el que tenga el mejor desempeño en estas métricas. Sin embargo en caso de que las diferencias no sean significativas se evaluará visualmente los frailejones identificados.

Build model:

Los hiperparámetros seleccionados para el modelo son:

- Número de unidades en la capa oculta: 64
- Número de épocas: 150
- Tasa de aprendizaje: 0.0001
- Función de activación: ReLU en capa oculta, Sigmoide en salida
- Función de pérdida: binary_crossentropy
- Optimizador: Adam

El modelo se define como una red secuencial con:

1. Una capa densa con 64 neuronas y activación ReLU.
2. Una capa de salida con una neurona y activación sigmoide para clasificación binaria.


Se utiliza ModelCheckpoint para guardar los pesos en cada época y se selecciona el mejor modelo según el desempeño en validación.

Assess model:


- Precisión en entrenamiento y validación:
 - Epoch 149: accuracy: 0.9835, val_accuracy: 0.9600
- Pérdida en entrenamiento y validación:
 - Epoch 149: loss: 0.0779, val_loss: 0.2628

Reportes de evaluación


- Curvas de pérdida y precisión: Se generaron gráficas mostrando la evolución de estos valores a lo largo de las épocas.



- Matriz de confusión: Permite visualizar los verdaderos positivos y negativos en la clasificación.



- Ubicación de predicciones positivas: Se visualizaron en la imagen original los puntos donde el modelo predice la presencia de frailejones.



RED NEURONAL MULTICAPA

Generate test design:

Para la red multicapa, el diseño de pruebas incluye los siguientes elementos:

- Mecanismos de comparación de técnicas: Se utiliza una estrategia de optimización con Optuna para encontrar la mejor configuración de hiperparámetros. Se comparan múltiples configuraciones de red utilizando una búsqueda bayesiana.
- Aumento de Datos.
- Variaciones de las técnicas: Se exploran diferentes configuraciones de unidades en cada capa, tasas de dropout y tasas de aprendizaje para determinar la mejor combinación.
- Preparación de bases de datos: Se dividen los datos en conjuntos de entrenamiento (80%) y validación (20%). Los datos se normalizan para mejorar la estabilidad del entrenamiento.
- Validación y prueba: Se emplea validación cruzada para evitar sesgos en el entrenamiento y asegurar la generalización del modelo.
- Mecanismos de control del sobreajuste/subajuste:
 - Se usa Dropout para regularizar la red y reducir el sobreajuste.

- Se implementa EarlyStopping para detener el entrenamiento cuando la pérdida en validación no mejora en cinco épocas consecutivas.
- Se entrena durante 50 épocas iniciales con Optuna y luego el mejor modelo se entrena por 150 épocas con almacenamiento de checkpoints.
- Selección de variables: Todas las variables relevantes fueron seleccionadas y normalizadas para asegurar que cada entrada tenga una influencia óptima en la red.

Build model:

Los hiperparámetros seleccionados para el modelo son:

- Número de capas ocultas: 2
- Número de unidades en la primera capa oculta: 85
- Número de unidades en la segunda capa oculta: 65
- Función de activación: Leaky ReLU
- Tasa de dropout en la primera capa: 0.20
- Tasa de dropout en la segunda capa: 0.21
- Tasa de aprendizaje: $8.28e-5$
- Función de pérdida: Binary Cross-Entropy
- Optimizador: Adam
- Métrica de evaluación: Accuracy

Mecanismos de selección de hiperparámetros:


- Se utiliza Optuna para la optimización de hiperparámetros.
- Se prueban múltiples combinaciones de hiperparámetros en 100 iteraciones de prueba.
- Se escoge la mejor combinación en función de una métrica ponderada de accuracy en entrenamiento y validación.

Assess model:


- Precisión en entrenamiento y validación:
 - Epoch 115: accuracy: 0.9700, val_accuracy: 0.9600
- Pérdida en entrenamiento y validación:
 - Epoch 115: loss: 0.0945, val_loss: 0.270

Reportes de evaluación


- Curvas de pérdida y precisión: Se generaron gráficas mostrando la evolución de estos valores a lo largo de las épocas.



- **Matriz de confusión:** Permite visualizar los verdaderos positivos y negativos en la clasificación. A pesar de tener un número de falsos positivos bajos, estos representan el 8.6% de las predicciones positivas del modelo.



- **Ubicación de predicciones positivas:** Se visualizaron en la imagen original los puntos donde el modelo predice la presencia de frailejones. Se evidencia un alto número de falsos positivos.



RED NEURONAL CONVOLUCIONAL

Generate test design:

- Aumento de Datos: El conjunto de datos original contenía 50 imágenes (21 de Frailejón, 29 de NoFrailejón). Se aplicaron técnicas de aumento de datos para generar 600 imágenes, asegurando una representación equilibrada de clases.
- Mecanismos de control del sobreajuste/subajuste:
 - Regularización: Se aplicó regularización L2 a las capas convolucionales.
 - Capas Dropout: Se implementaron capas dropout para prevenir el sobreajuste.
 - Early Stopping: Se detuvo el entrenamiento si la pérdida en validación no mejoraba en 10 épocas consecutivas.
 - Normalización por Lotes: Aplicada a las capas convolucionales para mejorar la estabilidad del entrenamiento.

Build model:

Los hiperparámetros seleccionados para el modelo son:


- Número de filtros de la primera capa convolucional: 64
- Número de filtros de la segunda capa convolucional: 105
- Número de filtros de la tercera capa convolucional: 163
- Número de la primera capa densa: 170
- Número de neuronas de la segunda capa densa: 108
- Tasa de dropout: 0.158
- Función de activación: Leaky ReLU
- l2_reg: 7.32e-5
- leaky_relu_alpha: 0.113
- Tasa de aprendizaje: 1.67e-5

Assess model:


- Precisión en entrenamiento y validación:
 - Epoch 13: accuracy:1, val_accuracy: 1
- Pérdida en entrenamiento y validación:
 - Epoch 13: loss: 0.1508, val_loss: 0.177

Reportes de evaluación



- Curvas de pérdida y precisión: Se generaron gráficas mostrando la evolución de estos valores a lo largo de las épocas.



- Matriz de confusión: Permite visualizar los verdaderos positivos y negativos en la clasificación.



- Ubicación de predicciones positivas: Se visualizaron en la imagen original los puntos donde el modelo predice la presencia de frailejones.



RED NEURONAL CONVOLUCIONAL + VGG16 AJUSTE HIPERPARÁMETROS OPTUNA

Generate test design:

El modelo está basado en la arquitectura VGG16 preentrenada con ImageNet. Se realizan modificaciones para la clasificación binaria:

- Congelación de las primeras capas y ajuste fino de las últimas 10 capas.
- Uso de capas adicionales:
 - GlobalAveragePooling2D() para reducir dimensiones.
 - Dense(76, activation='relu') con Dropout(0.29).
 - Dense(74, activation='relu') con Dropout(0.24).
 - Dense(1, activation='sigmoid') para clasificación binaria.

Build model:

Los hiperparámetros seleccionados para el modelo son:

- units_1: 76
- dropout_1: 0.29
- units_2: 74
- dropout_2: 0.24
- learning_rate: 2.88e-05
- Optimizador: Adam


- Función de pérdida: binary_crossentropy

Se entrenó por 50 épocas con early stopping y checkpointing de pesos. Se seleccionó la mejor Assess model:


- Precisión en entrenamiento y validación:
 - Epoch 11: accuracy:1, val_accuracy: 1

Reportes de evaluación


- Curvas de pérdida y precisión: Se generaron gráficas mostrando la evolución de estos valores a lo largo de las épocas.



- Matriz de confusión: Permite visualizar los verdaderos positivos y negativos en la clasificación.



- Ubicación de predicciones positivas: Se visualizaron en la imagen original los puntos donde el modelo predice la presencia de frailejones.



Conclusiones:

En conclusión, se tiene que los modelos con mejor desempeño son el CNN y el CNN con VGG16. A pesar de tener métricas similares, el modelo de CNN con VGG16 visualmente tiene un desempeño superior al CNN simple. A partir de este modelo se realizó un GMM cluster para priorizar el cuidado de la zonas menos pobladas.

Metric	SNN	MNN	CNN	CNN_VGG16
Accuracy	96%	96%	100%	100%
Precision	91%	91%	100%	100%
Recall	100%	100%	100%	100%

Clustering:

