



Facultad de Ingeniería

Tópicos Avanzados en Analítica

Proyecto 2 Clasificación de Géneros de Películas

Proyecto 2 grupal

Clasificación de Géneros de Películas.

Luis Frontuso Garces, Miguel Humberto Zuñiga Paredes, Tannia Lucía Hernández Rojas,

Docente: Sergio Alberto Mora Pardo

BUSINESS UNDERSTANDING

Background: Este caso de estudio forma parte de un proyecto de análisis de datos que busca clasificar géneros de películas a partir de una descripción de la trama. Con el creciente volumen de contenido audiovisual disponible, la clasificación precisa permite mejorar la recomendación de películas y la organización de bases de datos.

Business goal:

1. Mejorar la experiencia del usuario al facilitar la búsqueda y recomendación de películas.
2. Aumentar la interacción y el tiempo de visualización en plataformas de streaming.

Business success criteria:

1. Incrementar la precisión del modelo de clasificación de géneros de películas
 - **KPI:** Aumento en la tasa de clics (CTR) sobre las recomendaciones de películas.

Data mining goal:

1. Desarrollar un modelo de clasificación eficiente y preciso para identificar géneros de películas a partir de sus tramas.
2. Identificar patrones en las características textuales de las tramas que lleven a resultados correctos en la clasificación.
3. Evaluar la efectividad del modelo en datos no vistos para asegurar su generalización.

Data mining success criteria:

1. **KPI:** Alcanzar un AUC (Área Bajo la Curva) superior a 0.89 en la evaluación del modelo.

DATA UNDERSTANDING

Describe data: Se utilizó un conjunto de datos compuesto por tramas de películas y sus correspondientes géneros. Este conjunto incluye:


- Cantidad de Muestras: Aproximadamente 11,278 tramas de películas.
- Géneros Posibles: Incluyen acción, comedia, drama, horror, entre otros.

- Formato de Datos: Cada trama se presenta como texto libre y se convierte en representación numérica a través del procesamiento de texto.
- Los datos fueron extraídos de un conjunto de datos de películas disponible públicamente, que incluye detalles sobre títulos, tramas y géneros.


Variable	Descripción	Tipo de dato	Ejemplo
year	Año de lanzamiento	int	2003
title	Título de la película	str	Most
plot	Trama de la película	str	Most is the story of a single father who takes..
genres	Género de la película	[str]	['Short', 'Drama']
rating	Representa una calificación numérica o de estrellas que resume la opinión colectiva de los espectadores, tomando valores entre 0 y 10.	float	8.0

Exploratory Data Analysis


Un análisis inicial reveló que los géneros estaban desbalanceados; algunos géneros tenían muchas más muestras que otros. Esto podría afectar el rendimiento del modelo. La distribución de géneros muestra la cantidad de películas por género, ayudando a visualizar esta desigualdad.



Se gráfica la frecuencia de las características más comunes en un conjunto de datos. Los elementos están organizados en orden descendente, lo que evidencia que algunos términos, como "the" y "of", aparecen con mucha más frecuencia que otros. Esto indica una posible predominancia de ciertas palabras clave en los datos analizados, lo que podría influir en el análisis posterior. La visualización ayuda a identificar patrones y encontrar posibles sesgos en el uso del lenguaje.



El mapa de calor presenta la concurrencia de géneros de películas, visualizando la frecuencia con la que diferentes géneros aparecen juntos en la misma película. Las celdas más oscuras indican una alta concurrencia, mientras que las más claras representan relaciones débilmente asociadas.



La nube de palabras es una herramienta visual que permite representar la frecuencia de palabras en un conjunto de textos. En este caso, se ha elaborado una nube de palabras que

DATA PREPARATION

Los pasos de este proceso incluyen:

- Eliminación de puntuación y caracteres especiales.
- Normalización de espacios y conversión a minúsculas.
- Se utilizó nltk para remover stopwords que no aportan significado relevante.
- Uso de spaCy para convertir diferentes formas de una palabra en su raíz.
- Implementación de TfidfVectorizer para convertir las tramas en un formato numérico, utilizando términos unigrama y bigramas, con un límite de 1000 características y considerando un mínimo de 50 documentos por término.

MODELING & EVALUATION

Select modeling techniques: Se implementaron varios modelos de machine learning, cada uno optimizado para mejorar la clasificación:

1. Random Forest Classifier.
2. Regresión Logística.
3. Multinomial Naive Bayes.
4. Ensamble

Random Forest Classifier

Hiperparámetros: Optimización usando Optuna.

Resultados:

- *Training*
 - *Resultados por clase:*

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.94864	1.000000	0.973643	0.948640	0.885079
Thriller-Horror	1.00000	0.009009	0.017857	0.686133	0.831150
Adventure-Action	0.00000	0.000000	0.000000	0.755374	0.842470
Animation	0.00000	0.000000	0.000000	0.967091	0.912315
Documentary	0.00000	0.000000	0.000000	0.947879	0.946967
History-War	0.00000	0.000000	0.000000	0.932661	0.904411
Film-Noir	0.00000	0.000000	0.000000	0.979836	0.936645
Sport	0.00000	0.000000	0.000000	0.964619	0.937001
Western	0.00000	0.000000	0.000000	0.970325	0.955735

- *Métricas globales:*

Metric	Value
Macro Precision	0.2165
Macro Recall	0.1121
Macro F1-Score	0.1102
Macro AUC	0.9058

- *Test*
 - *Resultados por clase:*

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.950193	1.000000	0.974461	0.950193	0.779969
Thriller-Horror	1.000000	0.004739	0.009434	0.675676	0.802051
Adventure-Action	0.000000	0.000000	0.000000	0.770270	0.794758
Animation	0.000000	0.000000	0.000000	0.966409	0.790020
Documentary	0.000000	0.000000	0.000000	0.947876	0.923097
History-War	0.000000	0.000000	0.000000	0.932432	0.880783
Film-Noir	0.000000	0.000000	0.000000	0.976062	0.828948
Sport	0.000000	0.000000	0.000000	0.971429	0.877242
Western	0.000000	0.000000	0.000000	0.969112	0.928137

- *Métricas globales:*

Metric	Value
Macro Precision	0.2167
Macro Recall	0.1116
Macro F1-Score	0.1093
Macro AUC	0.8450

Regresión Logística

Hiperparámetros: Optimización usando Optuna.

Resultados:

- *Training*
 - *Resultados por clase:*

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.949001	1.000000	0.973833	0.949020	0.910770
Thriller-Horror	0.846723	0.481081	0.613558	0.808065	0.897800
Adventure-Action	0.873211	0.332037	0.481127	0.824805	0.903278
Documentary	0.976744	0.153285	0.264984	0.955678	0.975734
History-War	0.960000	0.067797	0.126649	0.937036	0.946219
Sport	1.000000	0.037634	0.072539	0.965950	0.960385
Animation	0.000000	0.000000	0.000000	0.967091	0.953870
Film-Noir	0.000000	0.000000	0.000000	0.979836	0.941819
Western	0.000000	0.000000	0.000000	0.970325	0.971986

- Métricas globales:

Metric	Value
Macro Precision	0.6229
Macro Recall	0.2302
Macro F1-Score	0.2814
Macro AUC	0.9402

- Test

- Resultados por clase:

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.950560	1.000000	0.974653	0.950579	0.834882
Thriller-Horror	0.806373	0.389810	0.525559	0.770656	0.859406
Adventure-Action	0.738739	0.275630	0.401469	0.811197	0.848494
Documentary	0.904762	0.140741	0.243590	0.954440	0.963476
History-War	0.916667	0.062857	0.117647	0.936293	0.909634
Film-Noir	0.000000	0.000000	0.000000	0.976062	0.881431
Animation	0.000000	0.000000	0.000000	0.966409	0.856692
Sport	0.000000	0.000000	0.000000	0.971429	0.932083
Western	0.000000	0.000000	0.000000	0.969112	0.933481

- Métricas globales:

Metric	Value
Macro Precision	0.4797
Macro Recall	0.2077
Macro F1-Score	0.2514
Macro AUC	0.8911

Multinomial Naive Bayes

- *Training*
 - *Resultados por clase:*

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.948640	1.000000	0.973643	0.948640	0.902938
Thriller-Horror	0.837427	0.430030	0.568254	0.793038	0.883504
Adventure-Action	0.836257	0.333593	0.476932	0.821001	0.883762
Documentary	0.977778	0.160584	0.275862	0.956059	0.976137
History-War	1.000000	0.098870	0.179949	0.939319	0.945813
Sport	1.000000	0.037634	0.072539	0.965950	0.962906
Animation	0.000000	0.000000	0.000000	0.967091	0.945714
Film-Noir	0.000000	0.000000	0.000000	0.979836	0.909452
Western	0.000000	0.000000	0.000000	0.970325	0.959725

- *Métricas globales:*

Metric	Value
Macro Precision	0.6222
Macro Recall	0.2290
Macro F1-Score	0.2830
Macro AUC	0.9300

- *Test*
 - *Resultados por clase:*

Genre	Precision	Recall	F1-Score	Accuracy	AUC
Other	0.950193	1.000000	0.974461	0.950193	0.805386
Thriller-Horror	0.792553	0.353081	0.488525	0.759073	0.857736
Adventure-Action	0.728033	0.292437	0.417266	0.812355	0.843432
Documentary	0.947368	0.133333	0.233766	0.954440	0.960697
History-War	0.846154	0.062857	0.117021	0.935907	0.897375
Film-Noir	0.000000	0.000000	0.000000	0.976062	0.780854
Animation	0.000000	0.000000	0.000000	0.966409	0.803707
Sport	0.000000	0.000000	0.000000	0.971429	0.900421
Western	0.000000	0.000000	0.000000	0.969112	0.899691

- Métricas globales:

Metric	Value
Macro Precision	0.4738
Macro Recall	0.2046
Macro F1-Score	0.2479
Macro AUC	0.8610

AUC Total

<u>Model</u>	<u>Training AUC</u>	<u>Testing AUC</u>
Random Forest Classifier	0.9058	0.8450
Regresión Logística	0.9402	0.8911
Multinomial Naive Bayes	0.9300	0.8610

Ensamble

Se itera sobre los diferentes géneros y se entrena un modelo de regresión logística para cada uno de ellos. Para cada género se revisa cuántas instancias son "positivas" (es decir, la película pertenece al género) y cuántas son "negativas" (no pertenece al género).

Si el número de positivos es menor a 400, se utiliza Leave-One-Out (LOO) para evaluación, donde se prueba cada instancia positiva en su propia evaluación.

Si hay suficientes positivos, se usa K-Fold (5 pliegues) para dividir los datos y evaluar el modelo.

AUC por género:

Género	AUC TRAIN	AUC TEST
Adventure-Action	0.8856	0.8296
Animation	0.9755	0.8957
Documentary	0.9882	0.9655
Film-Noir	0.9786	0.8878
History-War	0.9386	0.8959
Other	0.9406	0.8293
Sport	0.9832	0.9255
Thriller-Horror	0.8884	0.8437
Western	0.9875	0.9368

Promedio de AUC:

Métrica	Valor
AUC PROMEDIO TRAIN	0.9518
AUC PROMEDIO TEST	0.8900

Probabilidades de Géneros para Nuevo Plot:

Género	Probabilidad
Adventure-Action	0.65
Animation	0.17
Documentary	0.11
Film-Noir	0.01
History-War	0.59
Other	0.83
Sport	0.02
Thriller-Horror	0.23
Western	0.13

Se consideran los géneros que superan el umbral dinámico (media + std) igual a 0.59.

Conclusiones:

La clasificación de géneros de películas a partir de tramas muestra resultados prometedores. La regresión logística se destacó como el modelo más efectivo con un AUC de 0.89, lo que resalta su capacidad para manejar esta tarea. Sin embargo, todos los modelos enfrentan dificultades para clasificar géneros que no están bien representados en el conjunto de datos.

Considerando el desbalance en las categorías, se considera ensamble como una alternativa efectiva para alcanzar los valores esperados.