

ANÁLISIS Y CLASIFICACIÓN DE PRODUCTOS EN AMAZON COMPUTERS MEDIANTE MACHINE LEARNING EN GRAFOS

Integrantes: Luis Frontuso Garcés, Miguel Zúñiga Paredes, Tania Hernández Rojas

INTRODUCCIÓN:

Amazon se enfrenta al desafío constante de optimizar sus sistemas de recomendación y clasificación de productos. En este proyecto, se analiza la red de productos informáticos de la plataforma, donde cada nodo representa un producto y las aristas indican relaciones de co-compra, es decir, conexiones entre artículos que suelen adquirirse juntos ("los clientes que compraron este artículo también compraron...").

PROBLEMAS PRINCIPALES:

1. Categorización automática de productos:

- Las plataformas de e-commerce como Amazon tienen millones de productos que necesitan ser correctamente categorizados.
- La categorización manual es costosa, lenta y propensa a errores.
- Se busca desarrollar un sistema automático que pueda clasificar productos en sus categorías correctas basándose en sus relaciones de co-compra con otros productos.

2. Recomendación personalizada y relevante:

- Los sistemas tradicionales de recomendación a menudo no capturan relaciones complejas entre productos.
- Se busca mejorar las recomendaciones identificando productos relacionados que no serían evidentes usando métodos convencionales.
- El objetivo es recomendar productos complementarios o sustitutos que aumenten la probabilidad de compra y la satisfacción del cliente.

3. Comprensión de la estructura del mercado:

- Identificar comunidades naturales de productos que forman nichos de mercado.
- Detectar productos "puente" que conectan diferentes categorías.

VENTAJAS DE LA IMPLEMENTACIÓN DE GRAFOS:

- Capturan relaciones contextuales entre productos interconectados
- Facilitan la identificación de comunidades de productos relacionados
- Aprovechan la similitud entre productos conectados

OBJETIVOS DEL PROYECTO:

- Desarrollar incrustaciones (embeddings) de nodos mediante técnicas de aprendizaje en grafos

- Diseñar un sistema de clasificación y un sistema de recomendación de productos basado en predicción de enlaces
- Optimizar hiperparámetros de los modelos para maximizar su rendimiento

CONJUNTO DE DATOS Y PREPROCESAMIENTO

Utilizamos el dataset Amazon Computers de PyTorch Geometric, con las siguientes características:

- 13,752 nodos (productos)
- 491,722 aristas (245,861 únicas sin contar dirección)
- 10 clases (categorías de productos)
- 767 dimensiones de características por nodo (vectores extraídos de revisiones)

El preprocesamiento incluyó:

1. Filtrado basado en importancia: Se calculó el grado de cada nodo, se ordenaron por grado descendente y se mantuvieron los nodos que acumulan el 80% de las conexiones totales
2. División en conjuntos de entrenamiento (80%), validación (10%) y prueba (10%)
3. Generación de muestras negativas (326,872) para el entrenamiento, igual número que aristas positivas
4. Generación de etiquetas sintéticas mediante comunidades, clustering y grados de nodos

ANÁLISIS EXPLORATORIO DE LA RED

Propiedades topológicas básicas

Tras analizar el grafo Amazon Computers, encontramos:

- **Número de nodos:** 13,752 productos
- **Número de aristas:** 491,722 (245,861 sin contar duplicados por dirección)
- **Densidad:** 0.00260028 (grafo extremadamente disperso)
- **Conexidad:** El grafo no es conexo, contiene 314 componentes
- **Componente gigante:** 13,381 nodos (97.3% del grafo)
- **Grado promedio:** 35.7564 conexiones por producto

La estructura muy dispersa (solo 0.26% de conexiones posibles están presentes) indica alta especificidad en las relaciones de co-compra, donde cada producto tiene vínculos relevantes con un pequeño subconjunto del catálogo total. La presencia de una componente gigante que abarca más del 97% de los nodos sugiere un ecosistema de productos mayormente interconectado, con pequeños nichos aislados.

ANÁLISIS DE CAMINOS

Para comprender la navegabilidad en la red:

- **Diámetro aproximado:** 10 (obtenido mediante muestreo)

- **Longitud media de caminos más cortos:** 3.3949 (muestreado)

La longitud media de caminos relativamente baja (aproximadamente 3-4 pasos) revela una propiedad de "mundo pequeño" típica de redes complejas, indicando que un usuario puede navegar eficientemente desde cualquier producto a otro en pocos clics. Esta característica facilita la exploración del catálogo y sugiere potencial para sistemas de recomendación efectivos.

MEDIDAS DE CENTRALIDAD

Mediante análisis de centralidad identificamos productos clave:

- | | |
|---|--|
| <ul style="list-style-type: none"> • Centralidad de grado: Los nodos 2138 (0.066066) y 12717 (0.044044) destacan como hubs | <ul style="list-style-type: none"> • Centralidad de cercanía: Nodo 12717 (0.094714) muestra mejor accesibilidad global |
| <ul style="list-style-type: none"> • Centralidad de intermediación: Nodos 12717 (0.057992) y 4316 (0.044592) funcionan como puentes | <ul style="list-style-type: none"> • Centralidad de vector propio: Nodo 2138 (0.441462) tiene máximo impacto en la red |

El nodo 12717 aparece consistentemente con alta centralidad en múltiples métricas, sugiriendo un producto extremadamente influyente que actúa tanto como hub (muchas conexiones) como puente (conecta diferentes segmentos). Estos productos centrales representan puntos estratégicos para promociones, ya que tienen potencial para influir en un amplio segmento del catálogo.

CLUSTERING Y COMUNIDADES

El análisis de agrupamiento reveló:

- | | |
|--|---|
| <ul style="list-style-type: none"> • Transitividad global: 0.107739 | <ul style="list-style-type: none"> • Tamaño promedio de comunidad: 2.84 nodos |
| <ul style="list-style-type: none"> • Coefficiente de clustering promedio: 0.344126 | <ul style="list-style-type: none"> • Tamaño máximo de comunidad: 96 nodos |
| <ul style="list-style-type: none"> • Comunidades detectadas (algoritmo Louvain): 352 en la muestra analizada | |

El alto coeficiente de clustering (0.344) indica una fuerte tendencia a formar comunidades cohesivas, probablemente reflejando categorías y subcategorías naturales de productos. La fragmentación en muchas comunidades pequeñas sugiere un mercado altamente especializado con nichos bien definidos. Este hallazgo tiene implicaciones directas para estrategias de marketing y organización de catálogos.

ASORTATIVIDAD Y ANÁLISIS DE PUENTES

- **Coefficiente de asortatividad:** -0.056488
- **Análisis de puentes críticos:**
 - Nodos con grado ≤ 4 : 1,671 (12.15% del grafo)
 - Puentes identificados: 94

- Nodos que forman parte de puentes: 169 (16.90% del subgrafo filtrado)
- **Distribución de grados en puentes:**
 - Grado 1: 32 nodos (18.93%)
 - Grado 2: 42 nodos (24.85%)
 - Grado 3: 48 nodos (28.40%)
 - Grado 4: 47 nodos (27.81%)

El valor ligeramente negativo de asortatividad indica que no existe una clara preferencia por conexiones entre nodos de grado similar o diferente.

Filtrado basado en importancia

Implementamos un filtrado para trabajar con los nodos más relevantes que acumulan el 80% de las conexiones totales.

Resultado del filtrado:

- 5,620 nodos retenidos (40.9% del total)
- 326,872 aristas en el grafo filtrado
- Densidad: 0.010351 (aumentó de 0.00260028)

División de datos después del filtrado:

- Entrenamiento: 4,496 nodos (80%)
- Validación: 562 nodos (10%)
- Prueba: 562 nodos (10%)

GENERACIÓN DE EMBEDDINGS CON NODE2VEC

Implementamos Node2Vec con búsqueda exhaustiva de hiperparámetros usando Optuna (20 trials):

Rangos explorados:

- Dimensión de embedding: [32, 64, 128]
- Longitud de caminata: 15-35
- Número de caminatas por nodo: 100-400
- Parámetro de retorno (p): 0.25-2.0
- Parámetro de exploración-explotación (q): 0.25-4.0
- Épocas: 20-60
- Batch size: [128, 256, 512]
- Learning rate: 5e-4 - 5e-2

Parámetros óptimos encontrados:

- Dimensión de embedding: 128
- Longitud de caminata: 18
- Número de caminatas por nodo: 291
- Parámetro de retorno (p): 0.257

- Parámetro de exploración-explotación (q): 3.943
- Épocas: 22
- Batch size: 128
- Learning rate: 0.01997

El entrenamiento mostró una convergencia efectiva, con la pérdida final de 0.9695. La búsqueda reveló que valores bajos de p (favorecen exploración local) combinados con valores altos de q (desfavorecen retroceso) producen mejores resultados.

Al generar etiquetas sintéticas para los nodos mediante tres enfoques diferentes (comunidades, clustering y grado), observamos distribuciones distintas:

- **Etiquetas por comunidad:** Distribución más equilibrada entre clases
- **Etiquetas por clustering:** Concentración en ciertas clases dominantes
- **Etiquetas por grado:** Distribución muy sesgada hacia grados bajos

La visualización t-SNE de los embeddings reveló agrupaciones claras y coherentes de productos en el espacio bidimensional, confirmando que Node2Vec capturó efectivamente la estructura comunitaria del grafo.

Optimización de Hiperparámetros

Para maximizar el rendimiento, diseñamos una estrategia de optimización de hiperparámetros con Optuna (50 trials por modelo):

Rangos de hiperparámetros explorados

MLP, GCN y GAT:

- Capas ocultas: [64, 128, 256, 512]
- Número de capas: 2-4
- Dropout: 0.1-0.8
- Tasa de aprendizaje: $1e-4$ - $1e-1$
- Weight decay: $1e-6$ - $1e-2$

MODELOS DE CLASIFICACIÓN

Implementamos y comparamos tres arquitecturas para clasificación de productos, utilizando embeddings previamente generados:

MLP (Perceptrón Multicapa)

Arquitectura óptima encontrada:

- Dimensión de entrada: 128 (embeddings de Node2Vec)
- Capas ocultas: 3 capas con 128 neuronas cada una
- Dimensión de salida: 10 (clases)
- Dropout: 0.216
- Optimizador: Adam con $lr=0.0565$, $weight_decay=0.00032$
- Épocas: 75 (mejor época)

Resultados detallados:

- Precisión final de validación: 93.06%
- Precisión final de prueba: 91.10%
- Gap de sobreajuste: 0.0563

El modelo MLP mostró rápida convergencia, alcanzando más de 90% de precisión en las primeras épocas con estabilidad durante el entrenamiento.

GCN (Graph Convolutional Network)

Arquitectura óptima encontrada:

- Dimensión de entrada: 128 (embeddings de Node2Vec)
- Capas ocultas: 2 capas convolucionales con 64 unidades
- Dimensión de salida: 10 (clases)
- Dropout: 0.637
- Optimizador: Adam con $lr=0.0577$, $weight_decay=1.03e-6$
- Épocas: 57 (mejor época)

Resultados detallados:

- Precisión final de validación: 92.35%
- Precisión final de prueba: 90.57%
- Gap de sobreajuste: -0.0027

Para realizar el proceso de GCN implementamos la matriz de adyacencia (5,620×5,620) que representa las relaciones de co-compra entre productos filtrados con una densidad de 1.0351%. En nuestro proyecto, el modelo utiliza esta matriz explícitamente para propagar información mediante la operación $x = \text{norm_adj} @ x$, donde primero normalizamos la matriz usando los grados de los nodos.

GAT (Graph Attention Network)

Arquitectura óptima encontrada:

- Dimensión de entrada: 128 (embeddings de Node2Vec)
- Capas ocultas: 3 capas de atención con 16 unidades y 8 cabezas de atención
- Dimensión de salida: 10 (clases)
- Dropout: 0.163
- Optimizador: Adam con $lr=0.0195$, $weight_decay=1.20e-5$
- Épocas: 123 (mejor época)

Resultados detallados:

- Precisión final de validación: 93.42%
- Precisión final de prueba: 91.10%
- Gap de sobreajuste: 0.0049

El GAT mostró el comportamiento más equilibrado entre precisión de validación y prueba, con el mecanismo de atención permitiendo que el modelo asignara diferentes niveles de importancia a los vecinos.

ANÁLISIS COMPARATIVO

Modelo	Precisión Validación	Precisión Prueba	Gap Overfitting	Mejor Época
Node2Vec+MLP	93.06%	91.10%	0.0563	75
GCN	92.35%	90.57%	-0.0027	57
GAT	93.42%	91.10%	0.0049	123

Todos los modelos alcanzaron precisiones superiores al 90% en el conjunto de prueba, demostrando la efectividad de las representaciones basadas en grafos para la clasificación de productos. MLP y GAT lograron la mayor precisión en prueba (91.10%), con GAT mostrando mejor precisión en validación.

Las curvas de aprendizaje mostraron patrones interesantes:

- **MLP:** Convergencia más rápida y estable
- **GCN:** Convergencia más temprana (época 57) con menor sobreajuste
- **GAT:** Progreso más lento pero sostenido

PREDICCIÓN DE ENLACES

En esta etapa se implementan dos enfoques complementarios para predecir las conexiones entre nodos. Ambos métodos derivan en sistemas de recomendación capaces de sugerir productos que probablemente deberían estar conectados (co-comprados).

ENFOQUE 1: AUTOENCODERS DE GRAFOS

Este enfoque utiliza modelos específicos que aprenden a reconstruir la estructura del grafo:

Graph Autoencoder

- **Encoder:**
 - **Primera capa GCN (conv1)**
 1. Entrada: Toma como entrada las características originales de los nodos (767 dimensiones)
 2. Salida: representación intermedia de 128 dimensiones
 3. Activación: ReLU
 - **Segunda capa GCN (conv2)**
 1. Entrada: vector de 128 dimensiones por nodo
 2. Salida: 64 dimensiones - espacio latente (z) del modelo
- **Decoder:** Producto punto entre embeddings

Variational Graph Autoencoder (VGAE)

- **Primera capa GCN (conv1)**
 1. Proyecta las características de entrada de dimensión 767 a una dimensión oculta de 32
 2. Se aplica una función de activación ReLU
- **Segunda y tercera capa (conv_mu y conv_logstd):**
 1. Ambas reciben la salida de conv1
 2. conv_mu genera la media (μ) de la distribución latente (16 dimensiones)
 3. conv_logstd genera el logaritmo de la desviación estándar ($\log(\sigma)$)

Para el entrenamiento de los modelos se separaron aleatoriamente las aristas, en train, test, y validation con una proporción de 70, 20, 10. También se agregó negative sampling para que los modelos tengan información de los productos que no se compran en conjunto.

Optimización de Hiperparámetros

La optimización de hiperparámetros sobre ambos modelos se hizo en la tasa de aprendizaje de forma que se iteró sobre el siguiente rango y se seleccionó el modelo con mayor AUC en validation.

Lr = [0.0001, 0.0001668, 0.00027826, 0.00046416, 0.00077426, 0.00129155, 0.00215443, 0.00359381, 0.00599484, 0.01]

Graph Autoencoder

En este modelo se encontró que la tasa de aprendizaje con mejor desempeño fue de 0.0013 que alcanzó un 92.16% de AUC en validación con pérdida de entrenamiento de 0.5853 en la época 40.

Epoch	lr	train_loss	val_auc	test_auc
40	0.0013	0.5853	0.9216	0.9113

Variational Graph Autoencoder (VGAE)

En este modelo se encontró que la tasa de aprendizaje con mejor desempeño fue de 0.0013 que alcanzó un 92.83% de AUC y 92.23% de Average Precision.

Epoch	lr	train_loss	val_auc	val_ap
1000	0.0013	0.9744	0.9283	0.9223

ENFOQUE 2: PREDICCIÓN BASADA EN SIMILITUD DE EMBEDDINGS

Como alternativa, implementamos un método más directo que aprovecha los embeddings ya entrenados:

Metodología:

- División de datos: 80% train, 10% val, 10% test (130,748 / 16,343 / 16,345 enlaces)
- Generación de 16,345 muestras negativas para evaluación
- Cálculo de similitud de coseno entre pares de embeddings
- No requiere entrenamiento adicional

Resultados comparativos:

Método	Node2Vec	GCN	GAT
Similitud Coseno	AUC=0.9716, AP=0.9652	AUC=0.9215, AP=0.9136	AUC=0.8788, AP=0.8320
Graph Autoencoder	N/A	AUC=0.9077, AP=0.9098	AUC=0.9234, AP=0.9198
VGAE	N/A	N/A	N/A

Notablemente, Node2Vec muestra un rendimiento excepcional (97.16% AUC) con el método de similitud directa, superando significativamente a los autoencoders. Esto se debe a que Node2Vec está específicamente optimizado para preservar similitudes estructurales en el espacio de embeddings.

Sistema de recomendación

Con Autoencoders:

- Los autoencoders entrenados generan predicciones de enlaces que se traducen en recomendaciones de productos
- El decodificador produce scores de probabilidad para cada par de nodos, identificando productos que deberían estar conectados (co-comprados) pero actualmente no lo están
- La visualización de los grafos reconstruidos confirmó que los modelos capturan efectivamente la estructura de comunidades

Con Similitud de Embeddings:

- Calcula directamente la similitud entre un producto y todos los candidatos no conectados
- Retorna los productos con mayor similitud como recomendaciones
- Ejemplo de recomendaciones para el producto 50:
 - Producto 44: Score=0.8091
 - Producto 109: Score=0.7294
 - Producto 110: Score=0.6971
 - Producto 1460: Score=0.6811
 - Producto 57: Score=0.6711

Ventajas comparativas:

- **Autoencoders:** Más sofisticados, aprenden patrones complejos, mejor para GCN/GAT sin embeddings pre-entrenados
- **Similitud directa:** Más simple, computacionalmente eficiente, excelente para Node2Vec, implementación inmediata

Se implementaron dos enfoques complementarios para la predicción de enlaces: autoencoders de grafos y similitud directa de embeddings. Los autoencoders, adecuados para arquitecturas como GCN o GAT sin embeddings preentrenados, permiten un aprendizaje conjunto de representaciones y predicciones. En contraste, la similitud basada en Node2Vec, al contar con embeddings de alta calidad, logró mejores resultados (AUC=0.9716) con menor complejidad computacional. La comparación práctica entre ambos métodos evidenció que la elección depende del contexto y los recursos disponibles.

CONCLUSIONES

Hallazgos principales

1. Estructura de red altamente informativa: El análisis de la red Amazon Computers reveló propiedades topológicas distintivas con importantes implicaciones prácticas:
 - Alta dispersión (densidad 0.0026) pero fuerte estructura comunitaria (clustering 0.344)
 - Fenómeno de "mundo pequeño" con caminos cortos (longitud media 3.39) a pesar del gran tamaño
 - Productos clave como nodos 2138 y 12717 que funcionan como hubs y puentes estratégicos
2. **Efectividad de las representaciones de Node2Vec:**
 - Convergencia rápida del entrenamiento (pérdida final 0.9695)
 - Parámetros óptimos con $p=0.257$ y $q=3.943$ favorecen exploración con sesgo hacia adelante
 - Precisión superior al 90% en clasificación, demostrando la capacidad para capturar relaciones semánticas
3. **Rendimiento comparativo de modelos:**
 - MLP y GAT: Mejor rendimiento en prueba (91.10%)
 - GCN: Convergencia más rápida (época 57) con menor sobreajuste (-0.0027)
 - GAT: Mayor precisión en validación (93.42%) con balance óptimo
4. **Efectividad en predicción de enlaces:**
 - Graph Autoencoder: AUC de 92.16% en validación, 91.13% en test

- VGAE: Mejor rendimiento con AUC de 92.83% y AP de 92.23%
- Capacidad demostrada para identificar productos que deberían estar conectados

5. Sistema de recomendación efectivo:

- Modelos capaces de predecir co-compras con alta precisión (>92% AUC)
- Identificación de relaciones no evidentes en datos directos
- Base sólida para recomendaciones personalizadas

Implicaciones prácticas de los modelos

Los hallazgos de este estudio tienen múltiples implicaciones para plataformas de e-commerce:

1. **Categorización automática de productos:** La precisión superior al 91% en clasificación sugiere que estos modelos podrían implementarse confiablemente para:
 - Automatizar etiquetado de nuevos productos
 - Identificar categorizaciones incorrectas en catálogos existentes
 - Crear taxonomías de productos basadas en datos, derivadas directamente de patrones de compra
2. **Recomendaciones personalizadas mejoradas:** Los modelos basados en grafos proporcionan base para recomendaciones más efectivas:
 - Capacidad para predecir conexiones futuras con alta precisión (AUC>92%)
 - Identificación de productos complementarios no evidentes en datos directos
 - Potencial para aumentar ventas cruzadas y valor de carrito promedio
3. **Optimización estratégica de catálogos:** El análisis de centralidad permite:
 - Identificar productos "ancla" (como nodos 2138, 12717) que deberían mantenerse siempre en stock
 - Priorizar productos que funcionan como puentes entre comunidades para maximizar conectividad del catálogo
 - Diseñar promociones dirigidas específicamente a productos con alta centralidad de intermediación

Este proyecto ha demostrado el potencial significativo del aprendizaje en grafos para comercio electrónico, proporcionando no solo alta precisión en tareas predictivas sino también insights accionables sobre la estructura del ecosistema de productos. Los resultados establecen una base sólida para desarrollos futuros en categorización automática, sistemas de recomendación personalizados y optimización estratégica de catálogos basada en datos.